

מבוא ללמידת מכונה ומדע הנתונים 320101

שנה"ל: תשפ"ד סמסטר: ב'

עבודה מסכמת

הוראות הגשה:

1. העבודה תבוצע ותוגש ע"י סטודנט יחיד או בזוג.
2. סטודנט/זוג אינו רשאי להיעזר בכל צורה שהיא בפתרון המטלה המסכמת של סטודנט/זוג אחר, או להסתייע בגורמים אחרים כלשהם.
3. כן ניתן להיעזר בכלי בינה מלאכותית כגון chatGPT, תחת התנאים הבאים:
 - א. יש לציין במפורש במסגרת ההגשה את כל המקומות בהם נעשה שימוש בתוצרים של כלים אלה.
 - ב. בכל שימוש בכלי יש לצרף את ה prompt שהוזן אליו, ואת הפלט שהתקבל ממנו (כנספחים להגשה).
 - ג. גם במקרים בהם הפלט נערך לפני ששולב בפתרון שהוגש, הנחיה ב' תקפה. במקרים אלה יש להבהיר מה בדיוק השינוי שנעשה, ומה הסיבה לביצוע השינוי על-ידי הסטודנט/ים המגיש/ים.
 - ד. אין לשלב בהגשה תוצר של כלי בינה מלאכותית ללא הבנה מלאה של התוצר, במידה השקולה לנדרש לשם כתיבתו מראשיתו ועד סופו על ידי הסטודנט/ים המגישים.
- שימו לב:** שימוש בכלי בינה מלאכותית ללא עמידה מלאה בסעיפים א-ד, שקולה להעתקה. בכל מקרה בו מתעורר ספק לגבי השימוש המותר בכלי בינה מלאכותית, נדרשת הסכמת המרצה לשימוש המבוקש מראש ובכתב.
4. את הפתרונות לשאלות המבוססות על קוד יש להגיש במחברת/ות jupyter עם תיעוד מלא של הקוד והתוצרים (גרפים, הדפסות טקסט וכיו"ב), כשכל מחברת מכילה את כל הדרוש להבנתה.
5. את הפתרונות לשאלות העיוניות, כולל הסברים מפורטים של כל שלבי הפתרון, יש להגיש במסמך Word/PDF. הקפידו לפרט הנחותיכם ולבסס את מסקנותיכם בתוצאות הניסויים שביצעתם, כולל גרפים/טבלאות וכיו"ב בכל מקום בו זה יכול לסייע – **לאיכותם ובהירותם של מרכיבים אלה יינתן משקל מרכזי בציון**.
למעוניינים בכך, ניתן לצרף להגשה סרטון MP4 קצר (עד 3 דקות לכל חלק במטלה) עם הסברים/הבהרות להגשה (יצורף כקישור להורדה במסמך). שימו לב כי סרטון כזה, אם יוגש, לא יהווה תחליף למסמך ולמחברות שתגישו.
6. למרצה שמורה האפשרות לזמן את הסטודנטים **להגנה (בהינה בעל פה)** לפני מתן ציון לעבודה.

בהצלחה !!

אנא אשר/י: הנני מתחייב/ת לעבודה עצמאית

חתימה _____
ת"ז לשם אישור _____

חלק ו: אימון מלא של מסווג QDA (35 נקודות)

הקדמה

בחלק זה של הפרויקט תאמנו מסווג מסוג QDA, שהוא פונקציה $f: \mathcal{R}^D \mapsto \{1, 2, \dots, C\}$ המשייכת לכל וקטור במרחב המאפיינים $x \in \mathcal{R}^D$ אחד מ- C ערכים $y \in \{1, 2, \dots, C\}$. המידע $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$ שישמש אתכם לאימון המסווגים מורכב מאוסף דוגמאות, כשכל x_n הינו מטריצה ריבועית במידם 28×28 (סה"כ 784 פיקסלים, כלומר בעבודה זאת $D=784$) המייצגת תמונה (grayscale) של פריט לבוש, ו- y_n התיוג של כל דוגמא מייצג את סוג הפריט ע"פ הפירוט להלן (ראו איור 1)

Label 0: T-shirt/top
Label 1: Trouser
Label 2: Coat
Label 3: Sandal
Label 4: Ankle boot

ראינו כי מסווג מסוג QDA מתבסס על שערור *maximum likelihood* של פרמטרי המודל הבא:

$$\forall c = 1, 2, \dots, C:$$

$$P(x|y = c, \mu_c, \Sigma_c) = \mathcal{N}(x|\mu_c, \Sigma_c)$$

$$P(y = c) = \pi_c$$

$$0 \leq \pi_c \leq 1 \quad (\text{and} \quad \sum_{c=1}^C \pi_c = 1)$$

וכי בהינתן שיערוכי הפרמטרים של המודל $\theta = \{\pi_{c,ML}, \mu_{c,ML}, \Sigma_{c,ML}\}_{c=1}^C$, ניתן להשתמש בחוק בייס באופן הבא

$$\begin{aligned} P(y = c|x, \theta) &= \frac{P(x|y = c, \mu_{c,ML}, \Sigma_{c,ML})P(y = c)}{\sum_{c'=1}^C P(x|y = c', \mu_{c',ML}, \Sigma_{c',ML})P(y = c')} \\ &= \frac{\mathcal{N}(x|\mu_{c,ML}, \Sigma_{c,ML})\pi_{c,ML}}{\sum_{c'=1}^C \mathcal{N}(x|\mu_{c',ML}, \Sigma_{c',ML})\pi_{c',ML}} \\ &\propto \mathcal{N}(x|\mu_{c,ML}, \Sigma_{c,ML})\pi_{c,ML} \quad \forall c = 1, 2, \dots, C \end{aligned}$$

ולסווג כל דוגמא x ע"פ הכלל

$$\begin{aligned} (1) \hat{y}(x) = f(x) &= \underset{c=1,2,\dots,C}{\operatorname{argmax}} P(y = c|x, \theta) \\ &= \underset{c=1,2,\dots,C}{\operatorname{argmax}} \mathcal{N}(x|\mu_{c,ML}, \Sigma_{c,ML})\pi_{c,ML} \end{aligned}$$

כמו כן הגדרנו את דיוק (accuracy) המסווג $f(x)$, עבור הדאטה $\mathcal{D}$:

$$P_c(f, \mathcal{D}) = \frac{1}{N} \sum_{n=1}^N \mathbb{I}(y_n == f(x_n))$$



איור 1: דוגמאות לסוגי פרטי הלבוש.

כאשר $\mathbb{I}(A)$ היא פונקציית האינדיקטור

$$\mathbb{I}(A) = \begin{cases} 1 & \text{if } A \text{ is TRUE} \\ 0 & \text{otherwise} \end{cases}$$

שימו לב:

- בפתרונכם ניתן להשתמש בקוד שכתבתם במהלך הסמסטר בתרגילי הקידוד במעבדות ובמטלות הבית.
- בנוסף למחברת שתגישו, יש לצרף מסמך מלווה עם התשובות לחלקים העיוניים במטלה ופירוט תוצאות ניוסיים. בהירות ושלמות המסמך ישפיעו על הציון הסופי.

1. (1 נקודות) טענו את הדאטה שקיבלתם, והכינו אותו לאימון המסווג ע"י ייצוג כל תמונה כוקטור במרחב $\mathcal{R}^{784}$.

סדרת האימון מכילה 24,000 דוגמאות, כל אחת כוללת מטריצה במימד 28×28 (המאפיינים x) ותיוג y לכל אחת מהדוגמאות. אוסף כל התמונות נתון לכם כמטריצה תלת-ממדית במימד $28 \times 28 \times 24,000$, והתיוגים של כל הדוגמאות כוקטור באורך 24,000.

a. טענו את הדאטה הנתון בקובץ `TrainData.pkl`, הכולל את מטריצת התמונות ואת וקטור התיוגים של סדרת המבחן.

b. הציגו בתמונות נפרדות דוגמה אחת מכל אחד מהתיוגים הקיימים בדאטה, והוסיפו לתמונה את תיוגה ע"פ הדאטה.

c. הגדירו מטריצה חדשה במימד $24,000 \times 784$, כאשר השורה ה- n -ית בה מכילה וקטור באורך $28 \times 28 = 784$ עם ערכי כל הפיקסלים של הדוגמה ה- n -ית x_n (המתקבל לאחר שכל השורות בה שורשרו זו לזו).

הערה - ניתן לבצע הנ"ל על-ידי `np.reshape(...)`

2. (22 נקודות) ממשו את אלגוריתם האימון של מסווג QDA עבור מידע רב-ממדי כפי שלמדנו בקורס
 א. כתבו פונקציה המקבלת את סדרת האימון, ומחשבת את שערך maximum likelihood של כל אחד

$$\theta = \{\pi_{c,ML}, \mu_{c,ML}, \Sigma_{c,ML}\}_{c=1}^C$$

הערה I: ערכי הפיקסלים בתמונות שקיבלתם מוגדרים כמשתנה מסוג int8. בכדי להימנע מבעיות
 נומריות בשערוכי הפרמטרים מומלץ ראשית לשמור אותם בפורמט אחר דוגמת float64.
הערה II: בתשובתכם יש לחשב חישוב מלא את השערוכים (אין להשתמש בפונקציות כגון np.cov)
 ב. כתבו פונקציה נוספת המקבלת את כל פרמטרי המודל ששערכתם ודוגמאות לא מתויגות, ומחזירה את
 סיווג כל אחת מהתמונות ע"פ

$$\hat{y}(x) = \underset{c=1,2,\dots,C}{\operatorname{argmax}} P(y = c|x, \theta)$$

ג. יצגו כל אחד מהוקטורים הממוצעים ששערכתם כמטריצה ריבועית (כלומר יצגו כל וקטור באורך 784
 כמטריצה במימד 28x28) והציגו אותו כתמונה. הוסיפו לתמונה את התיוג הרלוונטי ודונו בקצרה בתוצאות
 שקיבלתם.

3. (4 נקודות) חשבו והציגו עבור סדרת האימון את

א. דיוק המסווג $P_c(f, \mathcal{D})$

ב. מטריצת הערבול

ג. ה- precision, recall של כל אחד מהתיוגים

דונו בתוצאות שקיבלתם, תוך התייחסות מפורשת לכל אחד מהמדדים הנ"ל.


4. (8 נקודות) חיזרו על שאלות 2-3 עבור סדרת המבחן הנתונה בקובץ TestData.pkl. דונו בהרחבה בתוצאות

שקיבלתם, תוך התייחסות מפורטת לדומה ולשונה בין הביצועים שמדדתם עבור כל אחת מהסדרות.

חלק ו': אימון והערכת ביצועים של מסווג (30 נקודות)

הקדמה

בחלק זה של הפרויקט הינכם מתבקשים לאמן מסווג בינארי לסנטימנט של טקסט כחיובי או שלילי, בהתבסס על הייצוג שלו כפי שהוא מתקבל ממודל LLM נתון.



המידע ניתן לכם בשני הקבצים הבאים

- קובץ TextExamples.csv הכולל 3659 דוגמאות טקסט, יחד עם הסיווגים שלהן.
 - קובץ TextPretrainedEmbeddings.csv הכולל 3659 וקטורים (כל אחד מכיל 64 איברים) המייצגים את המשפטים בקובץ TextExamples (שימו לב - בכל אחד מהקבצים יש 3659 שורות מידע, כשהייצוג בשורה ה-n בקובץ TextPretrainedEmbeddings מייצג את המשפט בשורה ה-n בקובץ TextExamples).
- מטרתכם היא לבחור, מבין כל המסווגים שלמדנו בקורס, מסווג שלהערכתכם סיכויי לסווג נכון ייצוגים עתידיים שיתקבלו ע"י ה-LLM הינם הגבוהים ביותר.
5. (20 נקודות) מבין המסווגים KNN, QDA, LDA, GNB, Decision Tree, Random Forest מציאו את המסווג אשר, ע"פ תוצאות ניסויים, דיוקו הצפוי על דוגמאות עתידיות הינו הגבוה ביותר הניתן להשגה. הינכם מתבקשים לנמק בפירוט ובבהירות כל אחד מהשלבים בעבודתכם, את שיקוליכם בנוגע למסווג שבחרתם כולל ערכי ה hyperparameters שלו במידה ויש כאלה, ומדוע לדעתכם סיכויי הדיוק שלו הם הגבוהים ביותר. בתשובתכם ציינו את המסווגים שבחנתם, תארו מילולית והציגו גרפית את התוצאות שקיבלתם, ונמקו את המסקנות שהגעתם אליהם בהתבסס על תוצאות הניסויים שביצעתם. יש להשתמש בכל השיטות שדנו בהן בהקשר של אימון מסווג כולל cross-validation, הערכת ההשפעה של מאפיינים שונים על ביצועי המסווג וכיו"ב, כמובן ע"פ הצורך ושיקול דעתכם.
6. (10 נקודות) כעת נמסר לכם שמודל ה-LLM הנ"ל עבר אימון נוסף (fine tuning), וכי הייצוגים של המידע המקורי כפי שהתקבלו על ידי המודל החדש נתונים לכם בקובץ TextFinetunedEmbeddings.csv הכולל אף הוא 3659 וקטורים באורך 64 איברים כל אחד (בתהליך ה fine tuning השתנו ערכי פרמטרי המודל ואיתם הייצוגים, אך מימד הייצוג נותר כפי שהיה).
- א. חזרו על שאלה 5 עבור הייצוגים החדשים.
- ב. דונו בדומה ובשונה בין בעית הסיווג ותוצאותיה עבור הייצוגים המתקבלים משני ה-LLM-ים הנ"ל.

חלק וו: רגרסיה (35 נקודות)

רקע:

בעיר מנדלייביה מתגוררים תושבים המרבים לנסוע מנקודה לנקודה בעיר, והם מעוניינים בפיתוח מערכת שתמליץ להם על נתיב מיטבי להגעה מכל נקודת מוצא לכל נקודת יעד. בעיר ישנן 96 נקודות שכל אחת מהן יכולה לשמש כמוצא, כיעד, או כנקודת מעבר לאורך הנתיב המקשר בין המוצא ליעד. המעבר בין כל זוג נקודות יכול להתבצע באופנים הבאים: א. בהליכה, ב. ברכב פרטי (במידה וכיוון הנסיעה מאפשר זאת), ו-ג. בתחבורה ציבורית (רק בין נקודות בהן קיימת אפשרות כזו). כדי להגיע מנקודת מוצא לנקודת יעד ניתן לייצר נתיב שמשלב את כל האופנים המתוארים.

ההתניידות בין כל נקודות מוצא ויעד נמדדת ע"פ משך הזמן הנדרש (במסגרת מטלה זאת נתעלם מזיהום האוויר הנוצר), והמערכת נדרשת לחשב את המסלול המהיר ביותר עבור כל בקשה הכוללת:

1. נקודת מוצא
2. נקודת יעד
3. תאריך וזמן היציאה

דאטה:

נתון לכם תיעוד של זמני הליכה ונסיעה (ברכב פרטי) כפי שנמדדו בזמנים שונים לאורך שנים, הכולל:

- נקודת התחלה
- נקודת סיום
- תיעוד של זמן תחילת המדידה
- משך הזמן שחלף בשניות

הערה: בכל המדידות, נקודות ההתחלה והסיום הינן נקודות סמוכות בעיר, שאין ביניהן נקודות נוספות.

בנוסף, נתון כי יש תחבורה ציבורית אשר:

- עוברת בין הנקודות הבאות ע"פ סדר רישומן למטה
- משך הנסיעה בין כל 2 נקודות סמוכות הוא בדיוק 4 דקות
- כלי תחבורה ציבורית נוסף יוצא למסלול כל 10 דקות
- מיד עם הגיעו לתחנת הסיום (Plutonium) מסתובב כלי התחבורה הציבורית ומתחיל במסלול חזרה עד לנקודה הראשונה (Beryllium)

- 1: Beryllium
- 2: Neon
- 3: Sulfur
- 4: Titanium
- 5: Nickel

- 6: Selenium
- 7: Zirconium
- 8: Palladium
- 9: Tellurium
- 10: Cerium
- 11: Gadolinium
- 12: Ytterbium
- 13: Osmium
- 14: Lead
- 15: Radium
- 16: Plutonium

רמז: העיר מנדלייביה נמצאת בצפון אמריקה.

7. (17 נקודות) במסגרת פתרוןכם הנכם נדרשים להגיש, עבור מי שמעוניין להתנייד אך ורק בהליכה, את:
- א. המסלולים שחושבו יחד עם הזמן המשוערך עבור כל אחת מהשאלות בקובץ המבחן המצורף. כל מסלול שיחושב, ידווח באופן הבא:
- זמן כולל של המסלול
 - פירוט הנקודות ביניהן הוא עובר
- ב. מחברת עם הקוד המלא, שלאחר הרצתה במלואה יחושב וידווח המסלול עבור כל צמד נקודות מוצא ויעד כלשהן שיינתנו בקובץ זהה במבנהו ובשמו לקובץ המצורף בשם Test.csv.
8. (16 נקודות) חיזרו על שאלה 7 עבור מי שמעוניין להתנייד אך ורק עם רכב.
9. (2 נקודות) חיזרו על שאלה 7 עבור מי שמוכן להתנייד בכל שילוב של רכב/תחבורה ציבורית/הליכה.

בהצלחה!